



**ESCUELA DE
POSGRADO
PUCP**

**MAESTRÍA EN GESTIÓN Y POLÍTICA
DE LA INNOVACIÓN Y LA TECNOLOGÍA**

Tema: Redes Sociales e Innovación
Prof. José Manuel Magallanes, PhD.

POL 748-Ciencia, Tecnología y Desarrollo

Comunidades y Modelos

Dos redes científicas, dos arquitecturas distintas

En esta sesión trabajaremos con dos redes de coautoría científica obtenidas desde Dimensions.

Red	Nodos	Enlaces
neuralNet	1495	1451
covidNet	13399	87524

Cada nodo representa un autor, y cada enlace representa una relación de coautoría entre dos autores.

Las redes de coautoría científica permiten estudiar cómo se organiza la producción de conocimiento dentro de una comunidad académica. Debido a que los enlaces representan colaboración efectiva entre investigadores, la estructura observada puede revelar patrones de:

- cohesión,
- fragmentación,
- circulación de información,
- y formación de grupos especializados.

Sin embargo, las propiedades observadas dependen fuertemente de cómo fue construida la red. En este ejercicio, las redes fueron elaboradas utilizando:

- publicaciones recientes,
- únicamente artículos científicos (excluyendo libros, capítulos o monografías),
- documentos indexados desde el área de ingeniería,
- y publicaciones disponibles en acceso abierto.

Además, las redes comparan temas muy distintos:

- un campo asociado a salud global (`covidNet`),
- y otro vinculado a computación e inteligencia artificial (`neuralNet`).

Por ello, las diferencias estructurales observadas no deben interpretarse únicamente como propiedades “naturales” de los campos científicos, sino también como consecuencia de:

- las decisiones metodológicas de recolección,
- los filtros utilizados,
- y el universo documental efectivamente observado.

Aun con estas limitaciones, las redes de coautoría permiten explorar cómo diferentes formas de colaboración producen arquitecturas científicas distintas.

```
In [1]: import networkx as nx
import requests
from io import StringIO

urlNeural = "https://raw.githubusercontent.com/maestriaInnovacion-magallanes-
urlCovid = "https://raw.githubusercontent.com/maestriaInnovacion-magallanes-

# neural network
responseNeural = requests.get(urlNeural)
neuralNet = nx.read_gml(StringIO(responseNeural.content))

# covid collaboration network
responseCovid = requests.get(urlCovid)
covidNet = nx.read_gml(StringIO(responseCovid.content))

print(neuralNet)
print(covidNet)
```

Graph with 1495 nodes and 1451 edges

Graph with 13399 nodes and 87524 edges

I. Conectividad

Un componente representa un conjunto de nodos conectados entre sí mediante algún camino.

```
In [2]: nx.number_connected_components(neuralNet), nx.number_connected_components(cc)
```

```
Out[2]: (838, 1755)
```

Los componentes **NO SON COMUNIDADES**, sino fragmentos completamente desconectados de la red.

¿Qué implica para la difusión de conocimiento que existan miles de componentes en una red de co-autores?

A primera vista ambas redes parecen muy fragmentadas.

Sin embargo, el tamaño del componente más grande cambia completamente la interpretación.

```
In [3]: max([len(c) for c in nx.connected_components(neuralNet)]), \
max([len(c) for c in nx.connected_components(covidNet)])
```

```
Out[3]: (18, 1402)
```

Red	Tamaño componente gigante
neuralNet	18
covidNet	1402

neuralNet presenta:

- muchísimos componentes pequeños,
- baja conectividad global,
- y ausencia de un componente gigante dominante.

Esto sugiere una red altamente fragmentada, donde gran parte de los autores no se encuentran conectados indirectamente entre sí.

La estructura observada limita potencialmente la alcanzabilidad global dentro de la red.

covidNet presenta una estructura distinta:

- un componente gigante considerablemente mayor,
- mayor conectividad indirecta,
- y una integración estructural mucho más amplia.

Esto sugiere que una gran cantidad de autores sí pertenece a una misma estructura conectada.

La existencia de un componente gigante aumenta potencialmente la capacidad de difusión y circulación indirecta dentro de la red.

Componente Gigante

Muchas métricas estructurales, como distancia promedio, diámetro o cercanía, requieren que exista conectividad entre nodos.

Por ello, es común realizar estos análisis sobre el componente gigante.

```
In [4]: maxNeural = max(
        nx.connected_components(neuralNet),
        key=len
    )

    maxCovid = max(
        nx.connected_components(covidNet),
        key=len
    )

    neuralGigante = neuralNet.subgraph(maxNeural)

    covidGigante = covidNet.subgraph(maxCovid)
```

```
In [5]: print(neuralGigante)
        print(covidGigante)
```

Graph with 18 nodes and 153 edges
Graph with 1402 nodes and 8235 edges

```
In [6]: # =====
        # FUNCION RESUMEN
        # =====
        import pandas as pd

        # Función para métricas globales del componente gigante
        def metricas_gc(G, nombre):
            return {
                "Red": nombre,
                "Nodos": G.number_of_nodes(),
                "Enlaces": G.number_of_edges(),
                "Diámetro": nx.diameter(G),
                "Distancia Media": nx.average_shortest_path_length(G),
                "Densidad": nx.density(G)
            }

        # Tabla
        tabla_gc = pd.DataFrame([
            metricas_gc(neuralGigante, "neuralGigante"),
            metricas_gc(covidGigante, "covidGigante")
        ])

        pd.options.display.float_format = "{:.4f}".format


        tabla_gc
```

Out [6]:

	Red	Nodos	Enlaces	Diámetro	Distancia Media	Densidad
0	neuralGigante	18	153	1	1.0000	1.0000
1	covidGigante	1402	8235	19	8.2491	0.0084

Las diferencias entre ambos componentes gigantes muestran arquitecturas estructurales profundamente distintas. El componente gigante de **neuralNet** corresponde a una estructura completamente conectada, donde todos los autores mantienen vínculos directos entre sí, produciendo máxima densidad y cohesión estructural.

In [7]: `nx.draw(neuralGigante)`



Sin embargo, esta cohesión ocurre dentro de un grupo muy pequeño, lo que contrasta con la fuerte fragmentación observada en la red completa. Por el contrario, **covidNet** presenta un componente gigante mucho más amplio e integrado, capaz de conectar indirectamente a más de mil autores, aunque con menor densidad, menor cohesión estructural y mayores distancias promedio. Esto sugiere dos configuraciones estructurales distintas: una basada en grupos pequeños altamente cohesionados y otra basada en una infraestructura de colaboración extensa con cohesión más débil.

II. Comunidades

El componente gigante de **neuralNet** no presenta suficiente complejidad estructural interna para realizar un análisis significativo de comunidades. Debido a que todos los nodos se encuentran directamente conectados entre sí, no existen agrupamientos internos, puentes ni regiones periféricas que permitan identificar subestructuras diferenciadas. Por ello, el análisis de comunidades resulta mucho más relevante en redes extensas y menos cohesionadas, como ocurre en el caso de **covidNet**.

Hasta ahora hemos analizado propiedades globales de las redes:

- densidad,
- distancia media,
- diámetro,
- alcanzabilidad.

Sin embargo, muchas redes sociales no se organizan homogéneamente.

Frecuentemente aparecen:

- grupos densos,
- zonas periféricas,
- regiones altamente conectadas,
- y puentes entre grupos.

Para entender esa organización interna analizaremos:

1. clustering coefficient,
2. transitivity,
3. cliques,
4. comunidades.

1. Clustering coefficient

El clustering coefficient mide hasta qué punto los vecinos de un nodo también se encuentran conectados entre sí.

En términos simples:

■ ¿Son mis amigos también son amigos entre sí?

Cuando el clustering es alto:

- aparecen triángulos,
- la cohesión local aumenta,

- y la red tiende a formar grupos densos.

En la figura 1, el nodo naranja mantiene cuatro vecinos (2, 3, 4 y 5). Entre esos vecinos podrían existir hasta seis conexiones posibles. A medida que aumentan las conexiones entre ellos (líneas rojas), el clustering coefficient del nodo aumenta progresivamente desde 0 hasta 1.




Figure 1. Average clustering coefficient.

Source: Ecology and Society

Cuando el valor es:

- cercano a 0, los vecinos casi no se conectan entre sí;
- cercano a 1, los vecinos forman un grupo altamente cohesionado.

Por ello, el clustering coefficient es una medida de cohesión local y cierre estructural.

```
In [8]: nx.average_clustering(covidGigante), nx.average_clustering(neuralGigante)
```

```
Out[8]: (0.9235709398210988, 1.0)
```

El clustering coefficient promedio muestra una diferencia importante entre cohesión global y cohesión local. Aunque **covidGigante** presenta una densidad muy baja (~ 0.0084), su clustering coefficient promedio es extremadamente alto (~ 0.92). Esto indica que, aun cuando la red es globalmente dispersa, los vecinos de cada nodo tienden fuertemente a conectarse entre sí, formando estructuras locales altamente cohesionadas. Nuestra red puede ser simultáneamente extensa y dispersa a nivel global, pero altamente cohesionada a escala local.

2. Transitivity

La transitivity mide la proporción global de triángulos observados en la red. Mientras el clustering coefficient promedio promedia el cierre local de cada nodo individualmente, la transitivity resume la tendencia global de la red a formar triángulos.

En la figura 2, la red comienza con varias tríadas abiertas: nodos que comparten un vecino común, pero que aún no se encuentran conectados entre sí. A medida que se

agregan enlaces laterales, las tríadas comienzan a cerrarse y aparecen más triángulos completos, aumentando progresivamente la transitivity de la red.

Por ello, valores altos de transitivity indican una fuerte tendencia global al cierre relacional y a la formación de agrupamientos cohesionados.




Figura 2. Transitividad

Fuente: Transitivity in a Graph

```
In [9]: nx.transitivity(covidGigante)
```

```
Out[9]: 0.7343307027714403
```


Un valor de transitivity de (0.734) indica que aproximadamente el 73% de las tríadas conectadas en la red terminan formando triángulos completos. En términos estructurales, esto significa que existe un nivel elevado de cierre relacional: cuando dos nodos comparten un vecino común, es altamente probable que también se encuentren conectados entre sí. Por ello, la red presenta una fuerte tendencia a formar agrupamientos locales cohesionados, aunque dicho cierre no es perfecto ni homogéneo en toda la estructura.

3. Cliques

Un **clique** se entiende como una comunidad de nodos donde todos están conectados unos con otros

3.1 Cliques Máximal

Una clique maximal es una clique que no puede ampliarse agregando nuevos nodos sin perder la propiedad de conexión completa entre todos sus miembros. En otras palabras, representa un grupo completamente conectado que ya no puede crecer dentro de la red.



- Cuantos maximales tenemos?

```
In [10]: len(list(nx.find_cliques_recursive(covidGigante)))
```

```
Out[10]: 221
```

La presencia de cliques puede sugerir la existencia de estructura comunitaria, ya que las cliques representan regiones de fuerte cohesión local dentro de la red.

4. Detección

Hasta ahora observamos que la red presenta:

- cohesión local,
- abundantes triángulos,
- y una fuerte tendencia al cierre relacional.

La siguiente pregunta es si esas estructuras producen agrupamientos más amplios dentro de la red.

Para responderla utilizaremos técnicas de detección de comunidades.

Una **comunidad** es un conjunto de nodos más densamente conectados entre sí que con el resto de la red. Una comunidad no es un componente: un componente corresponde a una subred completamente desconectada de otras dentro de la población de la red estudiada.

4.1 Método Louvain

Louvain es uno de los algoritmos más utilizados para detección de comunidades.

Su lógica consiste en:

1. asignar inicialmente cada nodo a su propia comunidad;

2. reasignar nodos iterativamente hacia comunidades vecinas si ello aumenta la modularidad;
3. agrupar las comunidades encontradas en supernodos;
4. repetir el proceso hasta que la modularidad deje de mejorar.

Louvain es:

- rápido,
- eficiente,
- y el algoritmo utilizado por defecto en Gephi para detección de comunidades.

```
In [11]: comunidadesCovid = nx.community.louvain_communities(
        covidGigante,
        seed=123
    )
```

Número de comunidades

```
In [12]: len(comunidadesCovid)
```

```
Out[12]: 26
```

Tamaño de comunidades

```
In [13]: tam_comunidades = sorted(
        [len(c) for c in comunidadesCovid],
        reverse=True
    )
plt.plot(tam_comunidades)
plt.xlabel("Comunidad")
plt.ylabel("Número de nodos")
plt.title("Tamaño de comunidades")
plt.show()
```

```
-----
NameError                                Traceback (most recent call last)
Cell In[13], line 5
      1 tam_comunidades = sorted(
      2     [len(c) for c in comunidadesCovid],
      3     reverse=True
      4 )
----> 5 plt.plot(tam_comunidades)
      6 plt.xlabel("Comunidad")
      7 plt.ylabel("Número de nodos")

NameError: name 'plt' is not defined
```

4.2 Partición

Aquí procedemos a asignar cada nodo a una comunidad:

```
In [ ]: louvain_attr={z:x for x,y in enumerate(comunidadesCovid) for z in y }
        nx.set_node_attributes(covidGigante, louvain_attr,'louvain')

        list(covidGigante.nodes(data=True))[:20]
```

5. Modularidad

La modularidad Q evalúa qué tan fuerte es la división interna de una red en comunidades.

Valores altos indican:

- grupos relativamente bien definidos,
- mayor densidad interna de conexiones,
- y menor cantidad relativa de enlaces entre comunidades.

Las técnicas modernas de detección de comunidades buscan maximizar la modularidad observada respecto de una red aleatoria equivalente.

Modularidad Q	Interpretación
< 0.3	estructura comunitaria débil
0.3 – 0.5	moderada
0.5 – 0.7	fuerte
> 0.7	muy fuerte

Veamos:

```
In [ ]: from networkx.algorithms.community.quality import modularity

        modularity(
            covidGigante,
            comunidadesCovid
        )
```

El valor observado de modularidad ($Q \approx 0.91$) indica una estructura comunitaria extremadamente fuerte. Esto significa que las comunidades detectadas presentan muchas más conexiones internas de las esperadas bajo una red aleatoria equivalente. En términos estructurales, la red muestra agrupamientos altamente diferenciados y relativamente bien separados entre sí.

```
In [ ]: pos = nx.spring_layout(
        covidGigante,
        seed=123
    )
```

```
In [ ]: plt.figure(figsize=(14,14))

nx.draw_networkx_nodes(
    covidGigante,
    pos,

    node_color=[
        covidGigante.nodes[n]["louvain"]
        for n in covidGigante.nodes()
    ],

    node_size=25,
    alpha=0.8
)

plt.axis("off")

plt.show()
```

Nota Técnica: Algorítmica de Detección de Comunidades

Existen múltiples algoritmos para detección de comunidades. Aunque difieren en sus estrategias computacionales, la mayoría busca identificar grupos de nodos más densamente conectados internamente que con el resto de la red.

Algunos métodos:

- maximizan modularidad (Louvain, Leiden),
- utilizan flujo de información,
- emplean propagación de etiquetas,
- aplican particiones espectrales,
- o estiman probabilidades de conexión entre nodos.

No existe un único algoritmo "correcto". Diferentes métodos pueden producir particiones distintas dependiendo:

- de la estructura de la red,
- del tamaño,
- de la densidad,
- y del tipo de agrupamientos presentes.

Por ello, la detección de comunidades debe entenderse como una aproximación analítica para explorar la organización interna de una red, y no como una identificación definitiva de grupos "reales".

Tabla Resumen de Métricas Observadas

Métrica	neuralNet	covidNet
Nodos	1495	13399
Enlaces	1451	87524
Número de componentes	838	1755
Tamaño componente gigante	18	1402
Densidad (GC)	1.0000	0.0084
Diámetro (GC)	1	19
Distancia media (GC)	1.0000	8.2491
Clustering coefficient	-	0.9236
Transitivity	-	0.7343
Número de cliques maximales	-	221
Número de comunidades Louvain	-	26
Modularidad (Q)	-	0.9080

III. Modelos de Red

Hasta ahora hemos analizado:

- conectividad,
- cohesión local,
- cierre triangular,
- y comunidades.

Sin embargo, una pregunta importante permanece abierta:

¿Qué tipo de mecanismos pueden producir estas estructuras?

Los modelos de red buscan responder precisamente esa pregunta.

Un modelo de red no intenta reproducir perfectamente una red real. Más bien, representa una aproximación simplificada de ciertos mecanismos de formación de enlaces.

Por ello, los modelos funcionan como herramientas interpretativas:

- ayudan a entender patrones estructurales,
 - comparar arquitecturas,
 - y generar hipótesis sobre procesos sociales subyacentes.
-

1. Modelo Erdős–Rényi (ER)

El modelo ER genera enlaces aleatoriamente entre nodos con una probabilidad (p).

Sus características típicas son:

- distribución relativamente homogénea de conexiones,
- ausencia de hubs importantes,
- bajo clustering,
- y poca estructura comunitaria.

Las redes ER suelen utilizarse como referencia basal o comparación frente a redes reales.

2. Modelo Barabási–Albert (BA)

El modelo BA introduce el mecanismo de “preferential attachment”:

■ los nuevos nodos tienden a conectarse con nodos ya muy conectados.

Esto produce:

- hubs altamente conectados,
- distribución desigual de grado,
- y estructuras tipo “scale-free”.

Las redes BA suelen asociarse con:

- difusión rápida,
 - concentración estructural,
 - y fuerte dependencia de actores centrales.
-

3. Modelo Watts–Strogatz (WS)

El modelo WS busca combinar:

- cohesión local,
- clustering alto,
- y distancias relativamente cortas.

Para ello:

- parte de una red regular,
- e introduce algunos enlaces aleatorios (“shortcuts”).

El resultado suele ser una red:

- altamente agrupada,
- pero globalmente alcanzable.

Este tipo de arquitectura se conoce como:

small-world network.

III. Modelos como aproximaciones

Las redes reales rara vez corresponden exactamente a un único modelo.

Sin embargo, los modelos ayudan a interpretar patrones estructurales observados.

Por ejemplo:

- redes con hubs prominentes pueden recordar estructuras BA;
- redes con fuerte clustering y comunidades pueden aproximarse a WS;
- redes sin estructura clara pueden parecerse más a ER.

Por ello, los modelos deben entenderse como aproximaciones analíticas para interpretar mecanismos potenciales de organización y no como descripciones exactas de la realidad.

1. Paso previo

Como paso previo antes de comparar nuestra `covidNet` debemos hacer cálculos que antes no hemos hecho:

- grado máximo observado,
- grado promedio,
- relación entre grado máximo y grado promedio,
- centralización de grado,
- y desigualdad estructural de conexiones.

Estas medidas permiten evaluar hasta qué punto la conectividad de la red se concentra en pocos nodos.

```
In [16]: import numpy as np
import pandas as pd

# grados
grados = dict(covidGigante.degree())

# vector de grados
```

```

valores_grado = np.array(
    list(grados.values())
)

# métricas
grado_maximo = valores_grado.max()

grado_promedio = valores_grado.mean()

ratio_max_mean = grado_maximo / grado_promedio

# centralización de Freeman
n = covidGigante.number_of_nodes()

centralizacion = sum(
    grado_maximo - d
    for d in valores_grado
) / ((n - 1) * (n - 2))

# coeficiente de variación
coef_variacion = (
    valores_grado.std() /
    valores_grado.mean()
)

# tabla resumen
tabla_ba = pd.DataFrame({

    "Métrica":[
        "Grado máximo",
        "Grado promedio",
        "Max / Promedio",
        "Centralización",
        "Coeficiente variación"
    ],

    "Valor":[
        grado_maximo,
        round(grado_promedio,2),
        round(ratio_max_mean,2),
        round(centralizacion,4),
        round(coef_variacion,4)
    ]
})

tabla_ba

```


Out [16]:

	Métrica	Valor
0	Grado máximo	91.0000
1	Grado promedio	11.7500
2	Max / Promedio	7.7500
3	Centralización	0.0566
4	Coeficiente variación	0.6834

Los resultados muestran que **covidNet** presenta cierta concentración estructural, aunque no extrema. El grado máximo observado (91) es considerablemente mayor que el grado promedio (~11.75), lo que indica que algunos autores ocupan posiciones más conectadas que el resto de la red. Sin embargo, la centralización global (~0.057) permanece relativamente baja, sugiriendo que la red no depende estructuralmente de unos pocos hubs dominantes. Del mismo modo, el coeficiente de variación (~0.68) muestra desigualdad moderada en la distribución de conexiones, consistente con una estructura parcialmente heterogénea pero no altamente jerárquica.

Síntesis: Evaluación Interpretativa de **covidNet** frente a Modelos de Red

Modelo	Propiedad esperada	Cumplimiento en covidNet	Evidencia observada
Erdős–Rényi (ER)	Baja estructura comunitaria	Bajo	Modularidad extremadamente alta ($Q \approx 0.91$)
Erdős–Rényi (ER)	Clustering relativamente bajo	Bajo	Clustering coefficient muy alto (≈ 0.92)
Watts–Strogatz (WS)	Alto clustering local	Alto	Fuerte cohesión local observada
Watts–Strogatz (WS)	Abundancia de triángulos	Alto	Transitivity elevada (≈ 0.73)
Watts–Strogatz (WS)	Conectividad global amplia	Alto	Componente gigante de 1402 nodos
Watts–Strogatz (WS)	Presencia de comunidades	Alto	26 comunidades y modularidad muy elevada
Barabási–Albert (BA)	Concentración parcial en hubs	Medio	Grado máximo claramente superior al promedio
Barabási–Albert (BA)	Estructura altamente centralizada	Bajo	Centralización global relativamente baja

Las propiedades observadas sugieren que `covidNet` exhibe varias propiedades frecuentemente asociadas a arquitecturas *small-world* (Watts–Strogatz), incluyendo clustering excepcionalmente alto (≈ 0.92), abundante cierre triangular y estructura comunitaria muy definida ($Q \approx 0.91$). Estos patrones son consistentes con mecanismos de cohesión local, cierre triádico y colaboración organizada en grupos relativamente estables.

Asimismo, la red presenta algunos indicios de concentración estructural parcial. El grado máximo observado (91) es considerablemente mayor que el grado promedio, aunque la centralización global permanece relativamente baja (≈ 0.057). Esto sugiere cierta heterogeneidad en la distribución de conexiones, compatible con elementos limitados de *preferential attachment*, pero sin la dependencia extrema de hubs dominantes característica de arquitecturas BA más puras.

In []: